# ESPECIFICACIÓN DE REQUERIMIENTOS DE SOFTWARE

# Sistema Inteligente de Predicción de Demanda

## MiniMarket La 24 S.A.S.

**Mateo Reyes** T00077079
**Elías José Blanco Gil** T00078817
**Sebastian Valencia Montesino** T00078248
**Jose Pereira Acuña** T00079768
**Fabián Corpas Castro** T00064976

*Ingeniería de Software • Abril 2025 • Versión 2.0*

# Control de Versiones

| Versión | Fecha | Descripción | Autor(es) | Estado |
|---|---|---|---|---|
| 1.0 | 01/04/2025 | Borrador inicial del SRS | Equipo consultor | Aprobado |
| 2.0 | 04/04/2025 | Revisión completa: trazabilidad, RNF ampliados, riesgos, arquitectura | Equipo consultor | Vigente |

# 1. Introducción

## 1.1 Propósito del Documento

Este documento constituye la Especificación de Requerimientos de Software (SRS) para el prototipo funcional del Sistema Inteligente de Predicción de Demanda de MiniMarket La 24 S.A.S. Está elaborado bajo el estándar IEEE 830 y define de manera completa, consistente y trazable los requisitos funcionales, no funcionales, restricciones de diseño y criterios de aceptación del sistema. Su audiencia principal son el equipo de desarrollo, el cliente y el comité evaluador académico.

## 1.2 Alcance del Sistema

El sistema, denominado internamente DEMAND-24, es un prototipo de predicción de demanda semanal por producto para el contexto de una cadena de tiendas de barrio. El sistema NO pretende reemplazar el juicio humano; su propósito es transformar los datos históricos de facturación en proyecciones accionables que apoyen las decisiones de reposición de inventario. El piloto abarca un subconjunto de productos estratégicos definidos por la gerencia.

## 1.3 Definiciones, Siglas y Abreviaturas

| Término / Sigla | Definición |
|---|---|
| **SRS** | Software Requirements Specification — Especificación de Requerimientos de Software. |
| **IA** | Inteligencia Artificial — conjunto de algoritmos que aprenden patrones a partir de datos. |
| **RF** | Requerimiento Funcional — comportamiento observable del sistema. |
| **RNF** | Requerimiento No Funcional — restricción de calidad, rendimiento o arquitectura. |
| **MAPE** | Mean Absolute Percentage Error — métrica de precisión del modelo predictivo. |
| **MAE** | Mean Absolute Error — error medio absoluto en unidades de producto. |
| **SKU** | Stock Keeping Unit — identificador único de producto en inventario. |
| **API** | Application Programming Interface — interfaz de programación entre componentes. |
| **ETL** | Extract, Transform, Load — proceso de ingesta y transformación de datos. |
| **DEMAND-24** | Nombre interno del sistema a desarrollar. |

## 1.4 Referencias


- IEEE Std 830-1998: Recommended Practice for Software Requirements Specifications.
- Hyndman & Athanasopoulos (2021). Forecasting: Principles and Practice, 3rd ed. OTexts.
- Documentación interna: actas de reunión con MiniMarket La 24 S.A.S., abril 2025.
- Martin Fowler (2002). Patterns of Enterprise Application Architecture. Addison-Wesley.

## 1.5 Visión General del Documento

El documento se organiza en ocho secciones: (1) Introducción, (2) Descripción General, (3) Requerimientos Funcionales, (4) Requerimientos No Funcionales, (5) Modelado del Sistema, (6) Arquitectura Propuesta, (7) Análisis de Riesgos y (8) Criterios de Aceptación. Cada requerimiento cuenta con identificador único, descripción, prioridad y criterio de verificación.

# 2. Descripción General del Proyecto

## 2.1 Perspectiva del Producto

DEMAND-24 es un sistema nuevo, independiente de los sistemas de producción actuales. Se integra de forma unidireccional con el sistema de facturación existente mediante un módulo ETL que extrae datos históricos de ventas sin modificar dichos sistemas. El sistema opera como una capa analítica desacoplada, exponiendo sus resultados a través de una interfaz web accesible desde los equipos de la tienda.

## 2.2 Funciones Principales del Producto

Las funciones principales del sistema son las siguientes:

- Ingesta y validación automática de datos históricos de ventas.
- Entrenamiento y versionamiento de modelos de predicción de demanda.
- Generación de predicciones semanales por SKU con intervalos de confianza.
- Generación de alertas automáticas de quiebre de stock proyectado.
- Visualización de tendencias históricas y proyectadas por producto y sucursal.
- Registro de ventas reales para retroalimentación y reentrenamiento del modelo.

## 2.3 Actores del Sistema

| Actor | Descripción | Interacción Principal |
|---|---|---|
| **Administrador de Tienda** | Responsable de la gestión operativa de cada sucursal. Realiza pedidos semanales y atiende alertas de inventario. | Consulta predicciones, revisa alertas, registra ventas reales. |
| **Gerencia General** | Supervisa el desempeño estratégico. Necesita visualizar tendencias de demanda a nivel macro sin involucrarse en la operación diaria. | Visualiza dashboards de tendencias y métricas de modelo. |
| **Área Financiera** | Monitorea el impacto económico del sistema: reducción de pérdidas por vencimiento y por ruptura de stock. | Consulta métricas de precisión y reportes de ahorro estimado. |
| **Sistema de Facturación** | Sistema externo que almacena el historial de ventas. Actor pasivo fuente de datos. | Origen de datos históricos para el módulo ETL. |
| **Modelo de IA** | Componente interno que ejecuta el ciclo entrena-predice-reentrena. | Es entrenado con datos históricos y genera predicciones consumidas por la capa de presentación. |

## 2.4 Restricciones Generales

- El sistema deberá desarrollarse como piloto de bajo costo con tecnologías de código abierto.
- No se modificará el sistema de facturación existente; la integración es de solo lectura.

- La arquitectura debe ser modular (desacoplada) para permitir extensiones futuras.
- El piloto operará sobre un subconjunto de SKU estratégicos definidos por la gerencia.
- La precisión del modelo estará limitada por la calidad y completitud de los datos históricos.

## 2.5 Suposiciones y Dependencias

- Los datos de ventas históricos están disponibles en el sistema de facturación con al menos 12 semanas de historia por SKU piloto.
- El área tecnológica del cliente proveerá acceso de lectura a la base de datos de facturación.
- Los administradores de tienda participarán en sesiones de capacitación de máximo dos horas.
- La infraestructura de despliegue será provista por el cliente (servidor local o instancia cloud básica).

# 3. Requerimientos Funcionales

La siguiente tabla especifica cada requerimiento funcional con su identificador único, prioridad (Alta / Media / Baja), nombre, descripción detallada y criterio de verificación. La prioridad refleja el impacto en los objetivos del piloto.

| ID | Prioridad | Nombre | Descripción | Criterio de Verificación |
|---|---|---|---|---|
| **RF-01** | **Alta** | **Ingesta de Datos (ETL)** | El sistema debe conectarse al sistema de facturación y extraer registros históricos de ventas (fecha, SKU, cantidad, precio unitario, sucursal). La extracción debe ser incremental: solo carga datos nuevos desde la última ejecución exitosa. | Prueba de integración: ejecutar ETL con datos de prueba, verificar que la tabla de ventas se actualice correctamente sin duplicados. |
| **RF-02** | **Alta** | **Validación de Datos** | Antes de entrenar o predecir, el sistema debe evaluar la calidad del dataset: cantidad mínima de registros por SKU (≥ 12 semanas), ausencia de valores nulos críticos y coherencia de fechas. Ante datos insuficientes emite mensaje de error descriptivo. | Prueba unitaria: cargar dataset con 8 semanas de historia; el sistema debe rechazar la predicción e indicar el motivo. |
| **RF-03** | **Alta** | **Generación de Predicción** | El modelo de IA debe generar, para cada SKU activo, una estimación de la demanda para las próximas 1–4 semanas, incluyendo límite inferior y superior del intervalo de confianza al 90%. | Prueba de aceptación: el MAPE del modelo sobre el conjunto de validación debe ser ≤ 20% en al menos el 70% de los SKU piloto. |
| **RF-04** | **Alta** | **Alertas de Quiebre de Stock** | Si la demanda proyectada para la próxima semana supera el stock actual registrado para un SKU, el sistema genera una alerta visible en el dashboard del Administrador con el mensaje: 'Posible quiebre de stock: [SKU] — Demanda proyectada: X uds, Stock actual: Y uds.' | Prueba funcional: insertar un SKU con stock < demanda proyectada; verificar que la alerta aparece en menos de 5 segundos. |
| **RF-05** | **Media** | **Visualización de Tendencias** | El sistema debe mostrar, por SKU y sucursal, una gráfica de serie de tiempo con el historial de ventas de las últimas 12 semanas y la proyección de las próximas 4 semanas. Las bandas de confianza deben ser visibles y diferenciadas del valor central. | Prueba de usabilidad: un administrador debe ser capaz de interpretar la gráfica correctamente sin instrucciones adicionales en < 2 minutos. |
| **RF-06** | **Alta** | **Registro de Venta Real** | El Administrador puede registrar manualmente la venta real de la | Prueba funcional: registrar venta real, |

| | | | | |
|---|---|---|---|---|
| | | | semana cerrada para cada SKU. Este dato se almacena para calcular el error del modelo y disparar el proceso de reentrenamiento. | verificar que el MAE de la predicción correspondiente se actualiza en la vista de métricas del modelo. |
| **RF-07** | **Media** | **Evaluación y Reentrenamiento del Modelo** | Cada vez que se registren ventas reales de al menos 4 semanas nuevas, el sistema debe ejecutar un ciclo de reentrenamiento automático, versionando el modelo anterior y registrando las métricas de ambas versiones para comparación. | Prueba de regresión: tras reentrenamiento, el nuevo modelo no debe presentar un MAPE mayor en más del 5% al modelo previo sobre el mismo conjunto de validación. |
| **RF-08** | **Baja** | **Ajuste Manual de Predicción** | El Administrador puede sobreescribir la predicción generada por el modelo para una semana específica, justificando el ajuste (campo de texto). El ajuste queda registrado como 'manual' y no afecta el modelo. | Prueba funcional: aplicar ajuste manual, verificar que el campo 'AjusteManual' queda en true y la cantidad ajustada se usa en los cálculos de alerta. |
| **RF-09** | **Media** | **Comparación entre Sucursales (Gerencia)** | La Gerencia puede visualizar, en una vista de resumen, la demanda proyectada y el error histórico del modelo por sucursal para un SKU dado, permitiendo identificar sucursales con patrones atípicos. | Prueba de aceptación: seleccionar un SKU con datos de al menos 2 sucursales; la vista debe renderizar la comparativa correctamente. |

# 4. Requerimientos No Funcionales

| ID | Categoría | Especificación |
|---|---|---|
| **RNF-01** | **Rendimiento** | El sistema debe generar predicciones para todos los SKU activos en un tiempo ≤ 30 segundos bajo carga normal (≤ 10 usuarios concurrentes). |
| **RNF-02** | **Disponibilidad** | El sistema debe estar disponible el 99% del tiempo en horario operativo (lunes a domingo, 6:00–23:00). Las ventanas de mantenimiento planificado se notificarán con 24 horas de anticipación. |
| **RNF-03** | **Usabilidad** | La interfaz debe ser comprensible para un administrador sin formación técnica. El tiempo de aprendizaje para las funciones principales no debe superar 2 horas con el manual de usuario incluido. |
| **RNF-04** | **Mantenibilidad** | El código fuente debe seguir principios SOLID, contar con cobertura de pruebas unitarias ≥ 70% y estar documentado con docstrings/JSDoc. Los modelos entrenados deben ser versionados con MLflow o equivalente. |
| **RNF-05** | **Escalabilidad** | La arquitectura debe permitir incorporar nuevos SKU o sucursales sin modificar el núcleo del sistema. La adición de un nuevo SKU debe requerir solo la configuración de datos, no cambios en el código. |
| **RNF-06** | **Seguridad** | El acceso al sistema debe requerir autenticación por usuario/contraseña. Los datos de ventas en tránsito deben ir cifrados (HTTPS/TLS 1.2+). No se almacenarán contraseñas en texto plano. |
| **RNF-07** | **Confiabilidad del Modelo** | Cuando el modelo no alcance el umbral de confianza establecido (MAPE > 25% en el conjunto de validación), el sistema debe mostrar la etiqueta 'PREDICCIÓN DE BAJA CONFIANZA' junto al resultado. |
| **RNF-08** | **Portabilidad** | El sistema debe ser desplegable en Linux (Ubuntu 22.04+) y en contenedor Docker, sin dependencias de software comercial. |
| **RNF-09** | **Trazabilidad** | Toda predicción generada debe quedar registrada en base de datos con: timestamp, versión del modelo, parámetros de entrada y resultado. Esta traza no puede ser borrada por ningún actor. |

# 5. Modelado del Sistema

## 5.1 Casos de Uso Principales

El flujo principal del sistema sigue la secuencia: el Administrador solicita una predicción → el sistema ejecuta el ETL incremental → valida calidad de datos → entrena o recupera el modelo vigente → genera predicciones con intervalos de confianza → evalúa si la predicción es confiable → muestra el resultado. Si la demanda proyectada supera el stock, se genera una alerta. Paralelamente, la Gerencia accede a vistas de tendencias y comparativas entre sucursales, y el Área Financiera consulta métricas de precisión del modelo.

## 5.2 Modelo de Dominio — Entidades Principales

| Entidad | Atributos Clave | Métodos / Responsabilidades |
|---|---|---|
| **Producto (SKU)** | IdProducto: int, Nombre: String, Categoría: String, UnidadMedida: String, StockActual: int, StockMínimo: int, Activo: boolean | obtenerCategoría(), verificarStock(), calcularBrechaStock() |
| **VentaHistórica** | IdVenta: int, Fecha: Date, Cantidad: int, PrecioUnitario: double, IdProducto: int, IdSucursal: int | obtenerSemana(), calcularTotal(), esDatoVálido() |
| **ModeloPredictivo** | IdModelo: int, Tipo: String (ej. SARIMA, XGBoost), Versión: String, FechaEntrenamiento: Date, Parámetros: JSON, Estado: String, MAPE: double, MAE: double | entrenar(), predecir(), reentrenar(), exportarMétricas() |
| **Predicción** | IdPredicción: int, IdModelo: int, IdProducto: int, IdSucursal: int, CantidadEstimada: int, LímiteInferior: int, LímiteSuperior: int, FechaGeneración: Date, AjusteManual: boolean, CantidadAjustada: int | aplicarAjuste(), compararConVentaReal(), calcularError() |
| **Alerta** | IdAlerta: int, IdPredicción: int, IdProducto: int, IdSucursal: int, Tipo: String, Mensaje: String, FechaGeneración: Date, Atendida: boolean | marcarAtendida(), notificar(), generarResumen() |
| **Sucursal** | IdSucursal: int, Nombre: String, Dirección: String, Activa: boolean | obtenerSKUsActivos(), obtenerHistorial() |

## 5.3 Flujo del Proceso Principal

El proceso de predicción sigue estos pasos en secuencia:

- El sistema recibe una solicitud de predicción (manual o automática programada).
- Se ejecuta el ETL incremental: se extraen solo los registros nuevos desde la última ejecución.

- Se valida la calidad de los datos: si hay menos de 12 semanas por SKU, el proceso se detiene con mensaje de error descriptivo.
- Si existe un modelo vigente entrenado recientemente (< 7 días), se recupera. Si no, se entrena uno nuevo.
- El modelo genera las predicciones para la próxima semana (y opcionalmente 2–4 semanas).
- Se evalúa la confianza: si MAPE > 25%, se etiqueta como 'baja confianza'.
- Se compara la predicción con el stock actual: si hay déficit proyectado, se genera una alerta.
- Los resultados se persisten en base de datos y se renderizan en la interfaz web.

# 6. Arquitectura Propuesta

## 6.1 Estilo Arquitectónico

La arquitectura propuesta sigue el patrón Hexagonal (Ports & Adapters) combinado con una separación en tres capas lógicas: Módulo de Datos (ETL + repositorios), Módulo Analítico (modelo de IA, entrenamiento, predicción) y Módulo de Presentación (API REST + interfaz web). Este estilo garantiza que el núcleo analítico sea independiente de la fuente de datos y de la capa de presentación, facilitando reemplazar cualquier componente sin afectar los demás.

## 6.2 Componentes del Sistema

| Componente | Responsabilidad | Tecnología Sugerida | RF/RNF Relacionados |
|---|---|---|---|
| **ETL Service** | Extracción incremental desde el sistema de facturación, limpieza y carga en el data warehouse. | Python + SQLAlchemy / Pandas | RF-01, RF-02, RNF-05 |
| **Data Store** | Almacenamiento de datos históricos, predicciones, alertas y métricas. | PostgreSQL / SQLite (piloto) | RF-01 – RF-09, RNF-09 |
| **ML Engine** | Entrenamiento, versionamiento y ejecución de modelos predictivos. | Python + scikit-learn / statsmodels + MLflow | RF-03, RF-07, RNF-04, RNF-07 |
| **Alert Engine** | Comparación de predicción vs. stock, generación y persistencia de alertas. | Python (microservicio) | RF-04, RNF-01 |
| **REST API** | Capa de exposición de servicios al frontend y sistemas externos. | FastAPI (Python) | Todos los RF, RNF-02, RNF-06 |
| **Web Dashboard** | Interfaz de usuario para administradores y gerencia. | React.js / Vue.js (SPA) | RF-04, RF-05, RF-08, RF-09, RNF-03 |
| **Auth Service** | Gestión de sesiones, autenticación y autorización por roles. | JWT + bcrypt | RNF-06 |

## 6.3 Principios de Diseño Aplicados

- Separación de responsabilidades (SRP): cada componente tiene una única razón de cambio.
- Desacoplamiento: el ML Engine no conoce el sistema de facturación; solo interactúa con el Data Store.
- Versionamiento de modelos: cada ciclo de entrenamiento genera una nueva versión registrada con sus métricas, sin sobrescribir la anterior.
- Configuración sobre código: los parámetros del modelo (hiperparámetros, umbrales, SKU piloto) se definen en archivos de configuración, no en el código fuente.

- Fail-safe: ante cualquier error en el ETL o el modelo, el sistema muestra el último resultado válido y registra el incidente en el log de auditoría.

# 7. Análisis de Riesgos

El siguiente registro identifica los riesgos más relevantes del proyecto, su nivel de impacto, descripción y estrategias de mitigación. Los riesgos se revisarán al final de cada iteración de desarrollo.

| ID | Nivel | Nombre | Descripción | Estrategia de Mitigación | Relacionado |
|---|---|---|---|---|---|
| **R-01** | **Alto** | **Datos históricos insuficientes o de mala calidad** | El sistema de facturación puede contener inconsistencias, SKUs fusionados o periodos sin registros. | Ejecutar auditoría de datos en sprint 1. Definir criterio mínimo de 12 semanas por SKU. Implementar RF-02 con mensajes claros. | |
| **R-02** | **Alto** | **Baja adopción por parte de los administradores** | Resistencia cultural al cambio; percepción de amenaza a la autonomía. | Presentar el sistema como 'herramienta de apoyo', no de control. Involucrar a un administrador líder como champion desde sprint 2. | |
| **R-03** | **Medio** | **Overfitting del modelo en datos de piloto** | Con pocos SKU, el modelo puede ajustarse demasiado al histórico y fallar en nuevos patrones. | Usar validación walk-forward (time-series split). Implementar umbral de baja confianza (RNF-07). | |
| **R-04** | **Medio** | **Cambios en el sistema de facturación** | Una actualización del sistema fuente puede romper el conector ETL. | Diseñar el ETL con adaptadores intercambiables. Definir contrato de datos estable documentado. | |
| **R-05** | **Bajo** | **Sobreconfianza en las predicciones** | Gerencia podría tomar decisiones de inversión basadas únicamente en el modelo sin criterio humano. | Documentar explícitamente las limitaciones del modelo. Los intervalos de confianza son obligatorios en toda vista (RF-03). | |
| **R-06** | **Bajo** | **Deuda técnica por entrega de piloto** | Presión de tiempo puede llevar a comprometer la calidad del código. | Aplicar revisiones de código semanales. Mantener cobertura de | |

| | | | | | |
|---|---|---|---|---|---|
| | | | | pruebas ≥ 70% (RNF-04) desde el inicio. | |

# 8. Criterios de Aceptación del Piloto

El piloto se considerará exitoso si se cumplen los siguientes criterios al finalizar el periodo de evaluación (4 semanas de operación real):

| ID | Criterio | Métrica de Medición | Umbral de Éxito |
|---|---|---|---|
| **CA-01** | Precisión del modelo de predicción | MAPE sobre conjunto de validación hold-out | ≤ 20% en al menos el 70% de los SKU piloto |
| **CA-02** | Reducción de quiebres de stock | Comparativa de incidentes de quiebre semana a semana | Reducción ≥ 15% respecto a la línea base pre-piloto |
| **CA-03** | Reducción de sobrestock en perecederos | Unidades de producto vencido o en promoción urgente | Reducción ≥ 10% respecto a la línea base pre-piloto |
| **CA-04** | Adopción por administradores | % de semanas en que el administrador consulta la predicción | ≥ 80% de las semanas del piloto |
| **CA-05** | Disponibilidad del sistema | % de tiempo operativo en horario definido | ≥ 99% conforme a RNF-02 |
| **CA-06** | Tiempo de generación de predicciones | Segundos desde la solicitud hasta la visualización del resultado | ≤ 30 segundos conforme a RNF-01 |

## 8.1 Estrategia de Validación

La validación del modelo se realizará mediante validación cruzada temporal (walk-forward validation): se entrenará el modelo con los primeros N períodos y se evaluará sobre los M períodos siguientes, avanzando semana a semana. Este enfoque replica fielmente el escenario de uso real y evita el data leakage propio de la validación cruzada estándar en series de tiempo.

Las métricas principales serán MAPE (para evaluar el error relativo, comparables entre SKU de distinto volumen) y MAE (para entender el error absoluto en unidades). Adicionalmente, se registrará el Bias (sesgo sistemático) para detectar si el modelo tiende a sobreestimar o subestimar de forma consistente.